Trabalho Prático #02 -
K-means

Integrantes:

- Gilmar Silva de Medeiros Filho - 202320945
- Samuel de Oliveira Vanoni - 202320611

1. Introdução e Objetivo

O presente relatório consolida o desenvolvimento e a análise comparativa de uma implementação manual (Hardcore) do algoritmo K-means contra a implementação consolidada da biblioteca Scikit-Learn. A experimentação utilizou a base de dados Iris, isolando a variável alvo (*target*) para garantir a natureza não supervisionada da clusterização.

2. Avaliação de Agrupamentos e Tempos de Execução

Os testes foram conduzidos para k = 3 e k = 5 partições. A validação quantitativa baseou-se na métrica *Silhouette Score*, paralela à aferição do custo computacional de treinamento (fit) e inferência (predict).

- **k = 3**:

K-means Hardcore		
Silhouette Score	**Tempo fit (s)**	**Tempo predict (s)**
0,5528	0,003873	0,000075

K-means Sklearn		
Silhouette Score	**Tempo fit (s)**	**Tempo predict (s)**
0,5512	0,080587	0,000494

- **k = 5**:

K-means Harcore		
Silhouette Score	**Tempo fit (s)**	**Tempo predict (s)**
0,4931	0,001622	0,000077

K-means Sklearn		
Silhouette Score	**Tempo fit (s)**	**Tempo predict (s)**
0,4931	0,003971	0,000412

Ambas as abordagens apontam k = 3 como a configuração de maior coesão interna e separabilidade.

3. Análise de Desempenho Arquitetural

A qualidade geométrica dos agrupamentos foi estatisticamente idêntica entre as implementações. Contudo, a diferença no tempo de treinamento expõe uma característica arquitetural importante: a implementação Hardcore finalizou o fit em menor tempo no cenário primário (k = 3). Este comportamento não acusa ineficiência do Sklearn, mas reflete o overhead gerado por suas validações de segurança, paralelismo de threads e, fundamentalmente, pela execução de múltiplas inicializações probabilísticas (*n_init* ou *k-means++*) desenhadas para evitar a estagnação em ótimos locais. Em bases de alta dimensionalidade, a solução do Sklearn seria ordens de grandeza mais escalável.

4. Redução de Dimensionalidade e Espaço Latente

Sob a configuração ideal (k = 3), a Análise de Componentes Principais (PCA) foi aplicada para comprimir as features em 1 e 2 componentes. A projeção ortogonal bidimensional elucidou a mecânica dos agrupamentos: enquanto um cluster apresenta separabilidade linear impecável, os dois restantes compartilham uma fronteira difusa, dificultando a delimitação euclidiana perfeita.

5. Conclusão e Validação Externa

A aplicação cruzou a matriz de contingência dos clusters matemáticos gerados com as classes reais das espécies. O algoritmo isolou a espécie Setosa com 100% de precisão, enquanto apresentou dispersão controlada entre Versicolor e Virginica. Este resultado atesta a corretude das duas implementações algorítmicas, demonstrando que o particionamento matemático espelha adequadamente a sobreposição fisiológica real da base Iris.