Trabalho Prático #03 -
RNA

Integrantes:

- Gilmar Silva de Medeiros Filho - 202320945
- Samuel de Oliveira Vanoni - 202320611

1. INTRODUÇÃO E OBJETIVO

Este relatório detalha a implementação e avaliação de um algoritmo de Redes Neurais Artificiais, especificamente o Perceptron Multicamadas (MLP), para resolver problemas de classificação multiclasse. O escopo contempla as bases de dados *Iris* e *Wine*. Secundariamente, realiza-se uma análise comparativa de performance entre o modelo implementado e o algoritmo K-Nearest Neighbors, desenvolvido no escopo do Projeto #01.

2. METODOLOGIA E ARQUITETURA

A aplicação foi desenvolvida em linguagem Python, sob ambiente de *notebook*, utilizando a biblioteca Scikit-learn. O fluxo de dados de processamento obedeceu aos seguintes critérios:

- **Amostragem:** Divisão dos *datasets* em 80% para treinamento e 20% para testes, aplicando estratificação (*stratify = y*) para manter a representatividade das classes.
- **Pré-processamento:** Escalonamento obrigatório dos atributos preditores utilizando StandardScaler. A padronização foi estritamente aplicada (*fit_transform* no treino; *transform* no teste) para garantir a convergência da descida do gradiente.
- **Arquitetura do Modelo (MLPClassifier):**
  - **Camadas Ocultas**: 1 camada com 100 neurônios (100).
  - **Função de Ativação**: Função Linear Retificada (ReLU).
  - **Otimizador**: adam.
  - **Iterações Máximas**: 1000.

3. RESULTADOS OBTIDOS

A capacidade preditiva da arquitetura foi medida através de Matrizes de Confusão e extração de métricas globais ponderadas de forma macro.

3.1. **Base de Dados Iris** (3 classes, 4 atributos de dimensionalidade baixa)

- **Acurácia:** 96,67%
- **Precisão (Macro):** 96,97%
- **Revocação (Macro):** 96,67%
- ***Observação**:* A matriz de confusão indicou apenas um falso predito (1 instância da classe *versicolor* classificada como *virginica*).

3.2. Base de Dados Wine (3 classes, 13 atributos de complexidade não-linear)

- **Acurácia:** 97,22%
- **Precisão (Macro):** 97,78%
- **Revocação (Macro):** 96,67%
- ***Observação**:* Excelente separabilidade em cenário de maior dimensionalidade, com taxa de erro restrita a 1 instância isolada.

4. ANÁLISE COMPARATIVA: KNN vs MLP (Base Iris)

A execução do classificador MLP em contraste com os resultados obtidos pelo algoritmo KNN no projeto anterior revela o seguinte panorama de desempenho empírico:

- **MLPClassifier:** Atingiu estabilidade de 96,67% de acurácia.
- **KNN (K-Nearest Neighbors):** Atingiu um pico máximo de 93% de acurácia para hiperparâmetros k=1 e k=7, regredindo para 90% na faixa de k=3 e k=5.

O KNN não possui fase explícita de treinamento, inferindo as classes no momento do teste via cálculos de distâncias, o que aumenta o custo computacional de inferência à medida que o volume de dados escala. Em contrapartida, o MLP exige um custo algorítmico e tempo de máquina substancialmente maior no momento inicial (para o ajuste de pesos via *gradient descent*), porém retorna o vetor de predições de forma quase instantânea na fase operacional.

5. CONCLUSÃO

O algoritmo baseado em Perceptron Multicamadas demonstrou superioridade preditiva clara na formulação das fronteiras de decisão complexas frente à abordagem geométrica de agrupamento do KNN. Reitera-se que as premissas de padronização se confirmaram imperativas, garantindo que algoritmos orientados a pesos, sensíveis à variância de escala, atingissem convergência ótima em ambas as bases de teste.