

Trabalho Prático #05 - Algoritmos Genéticos: Otimização de Funções

Integrantes:

- Gilmar Silva de Medeiros Filho - 202320945
- Samuel de Oliveira Vanoni - 202320611

1. Introdução e Metodologia

O presente trabalho aborda a aplicação de um Algoritmo Genético (AG), uma técnica de busca e otimização baseada nos princípios da evolução biológica, para resolver um problema de maximização matemática. O objetivo fundamental é encontrar o valor máximo da função $f(x) = x^2 - 3x + 4$, restringindo o espaço de busca ao intervalo contínuo $X = [-10, +10]$.

A metodologia adotada consistiu na implementação estruturada de um AG utilizando a linguagem Python. O modelo computacional simula o processo de seleção natural através da criação de uma população inicial aleatória, que evolui ao longo de sucessivas gerações por meio de operadores genéticos (seleção, crossover e mutação). A simulação permite mensurar a eficiência do algoritmo ajustando variáveis críticas, como o tamanho da população e o número de gerações, para garantir a convergência ao ótimo global.

2. Implementação e Algoritmos

O algoritmo desenvolvido segue o pipeline clássico da computação evolutiva, garantindo a exploração do espaço de busca e a preservação das melhores características genéticas.

- **Codificação e Aptidão:** Cada indivíduo (solução candidata) é representado por um cromossomo num vetor binário de 5 bits, que é decodificado para um valor inteiro no intervalo estipulado. A qualidade de cada indivíduo (Aptidão) é avaliada diretamente pelo resultado da função $f(x)$.
- **Seleção por Torneio:** O sistema utiliza o método de torneio para a escolha dos reprodutores. Indivíduos são escolhidos aleatoriamente para competir, e o mais apto é selecionado. Isso favorece as melhores soluções sem eliminar completamente a diversidade genética da população.
- **Crossover de Um Ponto:** A recombinação genética ocorre com uma probabilidade de 70%. O algoritmo divide e cruza o material genético de dois pais em um ponto aleatório, gerando descendentes que herdaram características promissoras de ambas as partes.
- **Mutação:** Para evitar a estagnação em mínimos ou máximos locais, aplica-se uma taxa de mutação de 1%. Esse operador introduz pequenas alterações aleatórias (inversão de bits) nos descendentes, mantendo a diversidade ao longo das gerações.

3. Resultados: Avaliação e Métricas

Para avaliar o desempenho prático, o algoritmo genético foi acionado de forma automatizada sob quatro configurações distintas de hiperparâmetros, variando o tamanho da população (4 ou 30) e o limite de gerações (5 ou 20).

A Tabela 1 sumariza a comparação das métricas exatas extraídas do simulador:

Cenário de Teste	Melhor Solução Encontrada (x)	Aptidão (Valor de $f(x)$)	Cromossomo Dominante	Observação Analítica
$Pop = 4, Ger = 5$	-8	92	[0, 0, 0, 1, 1]	Convergência subótima prematura.
$Pop = 30, Ger = 5$	-10	134	[0, 0, 0, 0, 0]	Excelente diversidade acelerou o acerto.
$Pop = 4, Ger = 20$	10	74	[1, 1, 1, 1, 1]	Preso em um Ótimo Local.
$Pop = 30, Ger = 20$	-10	134	[0, 0, 0, 0, 0]	Convergência robusta para o Ótimo Global.

Fica evidente na tabela que configurações restritas geram problemas no processo exploratório. O cenário com 4 indivíduos submetido a 20 gerações ilustra o clássico fenômeno do "Ótimo Local": o algoritmo explorou a extremidade direita do gráfico, estabilizou no valor máximo local de 74 (para $x = 10$) e, por falta de diversidade, foi incapaz de migrar para a extremidade oposta que continha o Ótimo Global de 134 (para $x = -10$).

4. Conclusão

A elaboração deste trabalho prático atingiu o objetivo de demonstrar a capacidade de um Algoritmo Genético em lidar com a otimização matemática, além de evidenciar as disparidades críticas na gestão de parâmetros de IA.

O experimento validou que, embora operadores genéticos como crossover (70%) e mutação (1%) sejam eficientes, a restrição no tamanho da população atua como um limitador severo de performance, aprisionando a rede de busca em ótimos locais. Conclui-se que assegurar uma população volumosa logo na primeira geração é a estratégia mais assertiva para mapear rapidamente o espaço de busca, permitindo que a evolução natural foque na extremidade correta do gráfico e garantindo o esforço computacional no encontro do verdadeiro Ótimo Global da função.